



江南大学


第六章 函数逼近



插值法的缺点

已知离散点 $(x_i, y_i) (i=1, 2, \dots, n)$ 。求一个简单易算的近似函数 $\varphi(x) \approx f(x)$ 。

但是 ① n 很大。




② y_i 本身是测量值，不准确，即 $y_i \neq f(x_i)$ 。




插值和拟合几何解释



函数插值示意图



曲线拟合示意图



曲线拟合定义

曲线拟合函数 $\varphi(x)$ 不要求严格地通过所有数据点 (x_i, y_i) ，也就是说拟合函数 $\varphi(x)$ 在 x_i 处的残差(亦称偏差)

$$\delta_i = y_i - \varphi(x_i), i = 0, 1, 2, \dots, n$$

(3) 残差平方和达到最小 $\min\{\sum_i \delta_i^2\}$

按照准则 (3) 求得近似函数的方法称为最佳平方逼近，也称为曲线拟合（或数据拟合）的最小二乘法。



向量和连续函数的范数

- 常见向量范数 $X \in R^n$
 - 2-范数 $\|X\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$
 - 1-范数 $\|X\|_1 = \sum_{i=1}^n |x_i|$
 - ∞ 范数 $\|X\|_\infty = \max_{1 \leq i \leq n} |x_i|$

- 连续函数范数 $f \in C[a, b]$ $\|f\|_\infty = \max_{x \in [a, b]} |f(x)|$

注：范数定义空间X距离的概念

$$d(u, v) = \|u - v\|, \forall u, v \in X$$



内积空间



定义 2.6.2: 设 X 是数域 K (R 或 C) 上的线性空间, 在 $X \times X$ 到数域 K 上建立一个映射, 即 $\forall u, v \in X$, 有 K 中一个数值与之对应, 记为 (u, v) , 且满足: $\forall u, v, w \in X$ 及 $a \in K$

- (1) $(u + v, w) = (u, w) + (v, w)$;
- (2) $(au, v) = a(u, v)$;
- (3) $(u, v) = \overline{(v, u)}$, 其中 $\overline{(v, u)}$ 是 (v, u) 的共轭复数;
- (4) $(u, u) \geq 0$, 且 $(u, u) = 0 \Leftrightarrow u = \theta$

则称 (u, v) 称为 u 与 v 的内积。定义了内积的线性空间, 称为内积空间。

内积空间可定义范数 $\|u\| = \sqrt{(u, u)}$

又可以定义角度 $\cos(\widehat{u, v}) = \frac{(u, v)}{\|u\| * \|v\|}$

注: 内积为零等价于两向量正交 (垂直)



向量空间内积（离散内积）

例 2.6.6: 设 $x, y \in R^n$ (或 $\in C^n$), 记 $x = (x_1, x_1, \dots, x_n)^T$, $y = (y_1, y_2, \dots, y_n)^T$, 给
定一组实数 $w_i > 0$ ($i = 1, 2, \dots, n$), 定义

$$(x, y) = \sum_{i=1}^n w_i x_i \overline{y_i} \quad (2.6.4)$$

此内积也称为 R^n (或 C^n) 上的权系数为 $\{w_i\}$ 的加权内积,

它的范数为 $\|x\| = \sqrt{(x, x)} = \sqrt{\sum_{i=1}^n w_i x_i \overline{x_i}}$



连续函数内积

定义 2.6.3: 设 $[a,b]$ 是有限或无限区间。如果 $\rho(x) \in C[a,b]$ 且满足:

(1) $\forall x \in [a,b], \rho(x) \geq 0;$

(2) $\int_a^b x^k \rho(x) dx$ 存在且为有限值 ($k = 0, 1, 2, \dots$);

(3) 若对 $[a,b]$ 上的非负连续函数 $g(x)$, 有 $\int_a^b \rho(x)g(x)dx = 0$, 则 $g(x) = 0$ 。

则称 $\rho(x)$ 为区间 $[a,b]$ 上的一个权函数。

例 2.6.7: 设 $\rho(x)$ 是 $[a,b]$ 上给定的权函数, $\forall f, g \in C[a,b]$, 定义:

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx$$

$$\|f\|_2 = \sqrt{\int_a^b \rho(x) f^2(x) dx}$$

此为连续函数空间 $C[a,b]$ 上的权函数为 $\rho(x)$ 的 2-范数。



江南大学

第六章 函数逼近

第一节 数据拟合的最小二乘法





6.1.3 线性最小二乘法的一般形式

将 (6.1.1) 改为使得

$$\sum_{i=1}^n \omega_i \delta_i^2 = \sum_{i=1}^n \omega_i [y_i - \varphi(x_i, \theta)]^2$$

最小, 其中 $\omega_i > 0$ ($i = 1, 2, \dots, n$) 为加权系数, 反映该点的重要程度。

一般地, 设给定数据组 (x_i, y_i) ($i = 1, 2, \dots, n$), $\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x)$ 为已知的一组 $[a, b]$ 上线性无关的函数组, 选取近似函数为 $\varphi(x) \in H = \text{span}\{\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x)\}$, 则

$$\varphi(x) = a_0 \varphi_0(x) + a_1 \varphi_1(x) + \dots + a_m \varphi_m(x) \quad (6.1.5)$$

直线拟合取 $\varphi_0(x) = 1, \varphi_1(x) = x$

m次多项式拟合取

$$\varphi_0(x) = 1, \varphi_1(x) = x, \varphi_2(x) = x^2, \dots, \varphi_m(x) = x^m$$





线性最小二乘法的一般形式

使得 ω

$$S(a_0, a_1, \dots, a_m) = \sum_{i=1}^n \omega_i \delta_i^2 = \sum_{i=1}^n \omega_i [y_i - \varphi(x_i)]^2 = \min_{\Phi \in H} \left\{ \sum_{i=1}^n \omega_i [y_i - \Phi(x_i)]^2 \right\} \quad (6.1.6) \omega$$

注：残差的平方和最小的原问题转化为求多元函数的 $S(a_0, a_1, \dots, a_m)$ 的极小值问题 ω

由多元函数极值必要条件，得 $\frac{\partial S}{\partial a_j} = 0$ ，即 ω

$$\sum_{i=1}^n \omega_i [y_i - \varphi(x_i)] \varphi_j(x_i) = 0 \quad (j = 0, 1, \dots, m)$$

即正则方程组为 ω

$$\sum_{k=0}^m \underbrace{a_k}_{\omega} \left[\sum_{i=1}^n \omega_i \varphi_k(x_i) \varphi_j(x_i) \right] = \sum_{i=1}^n \omega_i y_i \varphi_j(x_i) \quad (j = 0, 1, \dots, m) \quad (6.1.7) \omega$$





线性最小二乘法的一般形式

$$(6.1.7) \text{ 等价于 } \sum_{k=0}^m \underline{a_k} (\underline{\varphi_k}, \underline{\varphi_j}) = \underline{(y, \varphi_j)}$$

正则方程组 (6.1.7) 矩阵形式可写成

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_m) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_m) \\ \vdots & \vdots & \cdots & \vdots \\ (\varphi_m, \varphi_0) & (\varphi_m, \varphi_1) & \cdots & (\varphi_m, \varphi_m) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} (y, \varphi_0) \\ (y, \varphi_1) \\ \vdots \\ (y, \varphi_m) \end{bmatrix} \quad (6.1.8)$$

定理 6.1.1 正则方程组 (6.1.8) 存在唯一解 (a_0, a_1, \dots, a_m) ，且相应的函数

$$\varphi(x) = \sum_{k=0}^m a_k \varphi_k(x)$$

满足关系式 (6.1.6)，即它是数据组 (x_i, y_i) ($i = 1, 2, \dots, n$) 的最小二乘解。






6.1.1 多项式拟合

例 6.1.1: 求数据表的最小二乘二次拟合多项式。

i	1	2	3	4	5	6	7	8	9
x_i	1	3	4	5	6	7	8	9	10
y_i	10	5	4	2	1	1	2	3	4

解: 根据数据表
附近。



在一条抛物线





故选择拟合函数为二次多项式⁴

$$\varphi(x) = a_0 + a_1x + a_2x^2, \quad ^4$$


$$\varphi_0(x) = 1, \varphi_1(x) = x, \varphi_2(x) = x^2. \quad ^4$$

将数据表代入:

$$\begin{cases} 9a_0 + 5a_1 + 5a_2 = 10 \\ 53a_0 + 38a_1 + 25a_2 = 5 \\ 381a_0 + 301a_1 + 125a_2 = 4 \end{cases}$$

其解为 $a_0 = 13.4$

项式为 $P_2(x) = 1$



二次拟合多



江南大学



线性最小二乘法 (线性代数)

例 6.1.1: 求数据表的最小二乘二次拟合多项式。

i	1	2	3	4	5	6	7	8	9
x_i	1	3	4	5	6	7	8	9	10
y_i	10	5	4	2	1	1	2	3	4


故选择拟合函数为二次多项式

$$\varphi(x) = a_0 + a_1x + a_2x^2,$$

$$\varphi_0(x) = 1, \varphi_1(x) = x, \varphi_2(x) = x^2.$$

$$\begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_9 & x_9^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_9 \end{bmatrix}$$

超定方程 $Aa = y$ 的最小二乘解



法方程组 $A^T Aa = A^T y$






线性最小二乘法 (线性代数)

法方程组

$$\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 \\ 1 & 9 & 16 & 25 & 35 & 49 & 64 & 81 & 100 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \\ 1 & 5 & 25 \\ 1 & 6 & 36 \\ 1 & 7 & 49 \\ 1 & 8 & 64 \\ 1 & 9 & 81 \\ 1 & 10 & 100 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix}$$
$$= \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 \\ 1 & 9 & 16 & 25 & 35 & 49 & 64 & 81 & 100 \end{bmatrix} \begin{bmatrix} 10 \\ 5 \\ 4 \\ 2 \\ 1 \\ 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}$$



$$\begin{cases} 9a_0 + 53a_1 + 381a_2 = 32 \\ 53a_0 + 381a_1 + 3017a_2 = 147 \\ 381a_0 + 3017a_1 + 25317a_2 = 1025 \end{cases}$$





6.1.2可化为多项式拟合类型

(一) 指数拟合

例 6.1.2: 已知 x 与 y 服从 $y = ae^{bx}$ (a, b 为常数) 的经验公式。现测得 x 与 y 的数据如下表:

x_i	1	2	3	4	5	6	7	8
y_i	15.3	20.5	27.4	36.6	49.1	65.6	87.8	117.6

试用最小二乘法确定 a 和 b , 以及 x 与 y 的近似函数关系。

两边取对数, $\tilde{y} = \ln y = \ln a + bx$ 中 \tilde{y} 和 x 是线性关系

其求解过程如下:

- (1) 求出数据组 $(x_i, \ln y_i)$ ($i=1, 2, \dots, n$) 的最小二乘拟合直线 $\tilde{y} = a_0 + a_1x$;
- (2) 两边取指数即得数据组 (x_i, y_i) ($i=1, 2, \dots, n$) 的最小二乘的指数拟合

$$y = e^{a_0 + a_1x} = e^{a_0} e^{a_1x}.$$




解：由经验公式两边取自然对数可得 $\ln y = bx + \ln a$ ，作函数表

$x_{i\varphi}$	1 φ	2 φ	3 φ	4 φ	5 φ	6 φ	7 φ	8 φ
$\ln y_{i\varphi}$	2.7279							3 φ

先求数据表的
(6.1.8)，得正则方

其解为 $a_0 = 2.4368$

因此， x 与 y 的边



代入式



江南大学

（二）分式线性拟合

如果数据点 (x_i, y_i) ($i=1, 2, \dots, n$) 的分布近似于分式线性函数 $y = \frac{1}{ax+b}$ 的图像

其求解过程如下：

(1) 求出数据组 $(x_i, \frac{1}{y_i})$ ($i=1, 2, \dots, n$) 的最小二乘一次拟合多项式 $\tilde{y} = ax + b$

$$(\tilde{y} = \frac{1}{y} = ax + b)$$

(2) 两边取倒数即得数据组 (x_i, y_i) ($i=1, 2, \dots, n$) 的最小二乘的分式线性拟合



若取拟合函数的形式为 $y = \frac{x}{ax+b}$

其求解过程如下：

(1) 求出数据组 $(t_i, \tilde{y}_i) = (\frac{1}{x_i}, \frac{1}{y_i})$ ($i=1, 2, \dots, n$) 的最小二乘拟合直线 $\tilde{y} = a + bt = a + \frac{b}{x}$

$$(\tilde{y} = \frac{1}{y} = \frac{ax+b}{x} = a + \frac{b}{x}, \quad t = \frac{1}{x})$$

(2) 两边取倒数得所求拟合函数 $y = \frac{1}{\tilde{y}} = \frac{1}{a + \frac{b}{x}} = \frac{x}{ax+b}$



可化为多项式拟合类型





曲线拟合方程	变换关系	变换后线性拟合方程
$y = ae^{bx}$	$\bar{y} = \ln y$	$\bar{y} = \bar{a} + bx (\bar{a} = \ln a)$
$y = ax^\mu + c$	$\bar{x} = x^\mu$	$y = a\bar{x} + c$
$y = \frac{x}{ax + b}$	$\bar{y} = \frac{1}{y}, \bar{x} = \frac{1}{x}$	$\bar{y} = a + b\bar{x}$
$y = \frac{1}{ax + b}$	$\bar{y} = \frac{1}{y}$	$\bar{y} = b + ax$
$y = \frac{1}{ax^2 + bx + c}$	$\bar{y} = \frac{1}{y}$	$\bar{y} = ax^2 + bx + c$
$y = \frac{x}{ax^2 + bx + c}$	$\bar{y} = \frac{x}{y}$	$\bar{y} = ax^2 + bx + c$



常见拟合类型 (1)


几种常见的数据拟合情况。图 (a) 表示数据接近于直线，故宜采用线性函数 $y = a_0 + a_1x$ 拟合；图 (b) 数据分布接近于抛物线。可采拟合；二次多项式 $y = a_0 + a_1x + a_2x^2$ 拟合；




常见拟合类型 (2)



图 (c) 的数据分布特点是开始曲线上升较快随后逐渐变慢, 宜采用双曲线型函数 $y = \frac{x}{a + bx}$ 或指数型函数 $y = ae^{-\frac{b}{x}}$ 图 (d) 的数据分布特点是开始曲线下降快, 随后逐渐变慢, 宜采用 $y = \frac{1}{a + bx}$ 或 $y = \frac{x}{a + bx^2}$ 或 $y = ae^{-bx}$ 等数据拟合。



(c)



(d)



例2 设某实验数据如下:

i	1	2	3	4	5	6
x_i	0	0.5	1	1.5	2	2.5
y_i	2.0	1.0	0.9	0.6	0.4	0.3

用最小二乘法求拟合曲线


解:看出这些点接近指数曲线,因而可取指数函数 $y = ae^{-bx}$ 作为拟合函数.

两边取对数,得线性模型

$$\ln y = \ln a - bx$$

令 $\bar{y} = \ln y, a_0 = \ln a, a_1 = -b$

$$\bar{y} = a_0 + a_1 x$$





则正规方程组为

$$\begin{cases} 6a_0 + a_1 \sum_{i=1}^6 x_i = \sum_{i=1}^6 \ln y_i \\ a_0 \sum_{i=1}^6 x_i + a_1 \sum_{i=1}^6 x_i^2 = \sum_{i=1}^6 x_i \ln y_i \end{cases}$$

其中 $\sum_{i=1}^6 x_i = 7.5$ $\sum_{i=1}^6 x_i^2 = 13.75$ $\sum_{i=1}^6 \ln y_i = -2.043302$ $\sum_{i=1}^6 x_i \ln y_i = -5.714112$

将以上数据代入上式正规方程组，得

$$\begin{cases} 6a_0 + 7.5a_1 = -2.043302 \\ 7.5a_0 + 13.75a_1 = -5.714112 \end{cases}$$

解得 $a_0 = 0.562302$, $a_1 = -0.772282$





由 $a_0 = \ln a$ 得 $a = e^{a_0} = e^{0.562302} = 1.754708,$

由 $a_1 = -b$ 得 $b = -a_1 = 0.772282$

于是得到拟合指数函数为

$$y = 1.754708e^{-0.772282x}$$





最小二乘法中的条件数

例 在区间[2,4]中等距11个节点 $x_1 = 2.0, x_2 = 2.2, \dots, x_{11} = 4.0$, 设 $y_i = 1 + x_i + x_i^2 + \dots + x_i^7, 1 \leq i \leq 11$, 求7次多项式的二乘拟合。

可知法方程组的精确解 $a_1 = a_2 = \dots = a_n = 1$

实际数值解

```
>> x=(2+(0:10)/5)';  
>> y=1+x+x.^2+x.^3+x.^4+x.^5+x.^6+x.^7;  
>> A=[x.^0 x x.^2 x.^3 x.^4 x.^5 x.^6 x.^7];  
>> c=(A'*A)\(A'*y)
```

```
>> cond(A'*A)
```

```
ans =
```

```
5.4507e+18
```

c =

6.1636

-11.7488

14.3537

-6.6933

3.6333

0.4644

1.0600

0.9971

当 n 较大时($n \geq 7$),其法方程的系数矩阵的条件数 $\text{cond}(A' * A)$ 一般较大, 所以往往是病态的, 因而给求解工作带来了困难。



江南大学



离散内积下的正交函数族

近年来, 产生一些直接解线性最小二乘问题的新方法, 例如**正交三角化方法**。另外, 如果能选取基函数

$$\varphi_k(x) (k = 0, 1, \dots, m)$$

使得 $k \neq j$ 时, $(\varphi_k, \varphi_j) = \sum_{i=1}^n \omega_i \varphi_k(x_i) \varphi_j(x_i) = 0$

当 $k = j$ 时, $(\varphi_k, \varphi_j) > 0$

这组基函数就称为以 $\{\omega_i\} (i = 1, 2, \dots, n)$ 权系数,

点集 $\{x_1, x_2, \dots, x_n\}$ 上的**正交函数族**。





正交函数族下最小二乘法

正则方程组可写为

$$\begin{bmatrix} (\phi_0, \phi_0) & & & \\ & (\phi_1, \phi_1) & & \\ & & \ddots & \\ & & & (\phi_m, \phi_m) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} (y, \phi_0) \\ (y, \phi_1) \\ \vdots \\ (y, \phi_m) \end{bmatrix}$$

解为

$$a_k = \frac{(y, \phi_k)}{(\phi_k, \phi_k)} = \frac{\sum_{i=1}^n \omega_i y_i \phi_k(x_i)}{\sum_{i=1}^n \omega_i \phi_k^2(x_i)} \quad (k = 0, 1, \dots, m)$$



构造离散正交多项式——Gram-Schmidt正交化方法

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_1(x) = x - \alpha_1 \\ \varphi_k(x) = (x - a_k)\varphi_{k-1}(x) - \beta_k\varphi_{k-2}(x) \end{cases} \quad k = 2, 3, \dots, m \quad (6.1.12)$$

其中

$$\alpha_k = \frac{(x\varphi_{k-1}, \varphi_{k-1})}{(\varphi_{k-1}, \varphi_{k-1})} = \frac{\sum_{i=1}^n \omega_i x_i \varphi_{k-1}^2(x_i)}{\sum_{i=1}^n \omega_i \varphi_{k-1}^2(x_i)} \quad k = 1, 2, \dots, m \quad (6.1.13)$$

$$\beta_k = \frac{(\varphi_{k-1}, \varphi_{k-1})}{(\varphi_{k-2}, \varphi_{k-2})} = \frac{\sum_{i=1}^n \omega_i \varphi_{k-1}^2(x_i)}{\sum_{i=1}^n \omega_i \varphi_{k-2}^2(x_i)} \quad k = 2, 3, \dots, m$$



离散正交多项式的最小二乘法

例 6.1.3: 利用正交函数族求下列所给数据表的最小二乘二次拟合多项式。

i	1	2	3	4	5	6	7	8	9
x_i	-1	-0.75	-0.5	-0.25	0	0.25	0.5	0.75	1
y_i	-0.2209	0.3395	0.8826	1.4392	2.0003	2.5645	3.1334	3.7601	4.2836

解: 按式 (6.1.12) 和 (6.1.13) 计算可得: $\varphi_0(x)=1$;

$$\alpha_1 = \frac{(x\varphi_0, \varphi_0)}{(\varphi_0, \varphi_0)} = \frac{\sum_{i=1}^9 x_i}{\sum_{i=1}^9 1} = \frac{0}{9} = 0, \quad \varphi_1(x) = x; \quad \alpha_2 = \frac{(x\varphi_1, \varphi_1)}{(\varphi_1, \varphi_1)} = \frac{\sum_{i=1}^9 x_i^3}{\sum_{i=1}^9 x_i^2} = 0,$$

$$\beta_2 = \frac{(\varphi_1, \varphi_1)}{(\varphi_0, \varphi_0)} = \frac{\sum_{i=1}^9 x_i^2}{\sum_{i=1}^9 1} = \frac{3.75}{9} = 0.41667, \quad \varphi_2(x) = x^2 - 0.41667。$$



由式 (6.1.10) 计算得:

$$a_0 = \frac{(y, \varphi_0)}{(\varphi_0, \varphi_0)} = \frac{\sum_{i=1}^9 y_i}{\sum_{i=1}^9 1} = \frac{18.1723}{9} = 2.01914$$

$$a_1 = \frac{(y, \varphi_1)}{(\varphi_1, \varphi_1)} = \frac{\sum_{i=1}^9 y_i x_i}{\sum_{i=1}^9 x_i^2} = \frac{8.4842}{3.75} = 2.2625$$

$$a_2 = \frac{(y, \varphi_2)}{(\varphi_2, \varphi_2)} = \frac{\sum_{i=1}^9 y_i (x_i^2 - 0.41667)}{\sum_{i=1}^9 (x_i^2 - 0.41667)} = \frac{0.04545}{1.2031} = 0.0378$$

将上述结果代入 (6.1.11) 即得最小二乘二次拟合多项式为

$$\begin{aligned}\varphi(x) &= a_0 \varphi_0(x) + a_1 \varphi_1(x) + a_2 \varphi_2(x) \\ &= 2.01914 + 2.2625x + 0.0378(x^2 - 0.41667) \\ &= 2.0034 + 2.2625x + 0.0378x^2\end{aligned}$$

